

Counterfactual Recurrent Model ve Nedensel Akıl Yürütme Modeli: Farklar ve Son Gelişmeler

Giriş: Nedensel Akıl Yürütme ve Karşı-Olgusal Düşünme

Nedensel akıl yürütme (causal reasoning), sistemlerde **neden-sonuç ilişkilerini** anlamayı ve “**eğer ... olsaydı ne olurdu?**” gibi soruları yanıtlamayı hedefleyen bir yaklaşımdır. Judea Pearl’ün sebep-sonuç merdivenine göre nedensel analiz üç düzeydedir: **birliktelik (korelasyon)**, **müdahale (deneysel etki)** ve **karşı-olgusal (counterfactual)** analiz ¹ ². Özellikle *karşı-olgusal çıkarım*, gerçekleşmemiş alternatif senaryoları düşünerek bir faktörün sonuc üzerindeki etkisini incelemeyi sağlar ³. Örneğin, bir hastaya farklı bir tedavi verilseydi sağlığı nasıl olurdu sorusu karşı-olgusal bir sorgudur. Nedensel akıl yürütme modelleri, bu tür soruları yanıtlamak için genellikle *yapısal nedensel modeller (SCM)* veya *Rubin’in potansiyel sonuç modeli* gibi çerçeveleri kullanır. Bu sayede verilerde gözlemlenen korelasyonları aşarak **gerçek nedensel etkileri** ortaya çıkarmaya çalışırlar ⁴ ⁵.

Diğer yandan, **karşı-olgusal düşünme** nedensel analizinin merkezinde yer alır ve tek bir faktörü değiştirerek sonuçların nasıl farklılaşacağını kurgular ³. Bu yaklaşım, özellikle karar destek sistemlerinde “*X faktörünü değiştirirsek sonuç Y nasıl etkilenir?*” sorusunu cevaplamak ve daha sağlam, genellenebilir çıkarımlar yapmak için kritiktir ⁶. Aşağıda, genel nedensel akıl yürütme modelleri ile **Counterfactual Recurrent Model (Karşı-Olgusal Tekrarlayan Model)** olarak adlandırılan özel bir derin öğrenme mimarisini karşılaştırarak, bunların çalışma mantığı, teknik yapıları, performans farkları ve açıklanabilirlik yönlerini inceleyeceğiz.

Nedensel Akıl Yürütme Modellerine Genel Bakış

Nedensel akıl yürütme modeli, geniş bir terim olup nedensel ilişkileri modelleyen her türlü yöntemi kapsar. Bu modeller, genellikle **nedensel grafikler** (yönlendirilmiş asiklik grafikler) veya **potansiyel sonuç** yaklaşımları üzerine kuruludur. Örneğin **Yapısal Nedensel Modeller (Structural Causal Models, SCM)**, değişkenler arası etkileşimleri gösteren bir nedensel ağ (DAG) ve her bir ok için yapısal eşitlikler tanımlar. Bu sayede model, herhangi bir değişkene müdahale edildiğinde (ör. bir faktör sabitlendiğinde) diğer değişkenlerin değerlerini hesaplayabilir; böylece *müdahale* ve *karşı-olgusal* sorulara formel olarak cevap verir. **Rubin’in Nedensel Modeli (Potansiyel Sonuçlar Çerçevesi)** ise her bir birimin her olası tedavi durumu için potansiyel sonuçları olduğunu varsayar ve **karşı-olgusal sonucu**, gözlemlenmeyen tedavi durumunun sonucunu tahmin ederek tanımlar ⁴ ⁵. Bu çerçevede **ortalama tedavi etkisi** veya **bireysel tedavi etkisi** gibi metrikler hesaplanabilir.

Nedensel akıl yürütme modelleri sadece istatistiksel ilişkilere bakmakla kalmayıp, **gizli karıştırıcı değişkenleri** (confounder) dengelemeye odaklanır. Örneğin, bir model *propensity score* (eğilim skoru) eşleştirmesi yapabilir veya *do-calculus* kurallarını kullanarak verideki karıştırıcı etkisini giderdikten sonra gerçek nedensel etkiyi hesaplayabilir ⁴. Bu alanda klasik yöntemler (örn. **BART**, **propensity score matching**) bulunmakla birlikte, son yıllarda **derin öğrenme tabanlı nedensel modeller** de öne çıkmıştır ⁷ ⁸. Derin modeller, büyük veriler üzerinde karmaşık nedensel ilişkileri öğrenebilme potansiyeli sunar ve **bireysel/ortalama tedavi etkisi (ITE/ATE)** tahmininde geleneksel yöntemlere kıyasla daha düşük hata elde edebilirler ⁸. Örneğin, 2022 yılında Domingo-Fernández ve arkadaşları, **ilaç keşfi** alanında *RPath* adında bilgi grafiğine dayalı bir nedensel çıkarım modeli geliştirerek, ilaç

etkilerini nedensel bağlantılar üzerinden analiz etmişlerdir ⁹ . Benzer şekilde, nedensel modeller **öneri sistemlerinden** ¹⁰ sağlık ve biyolojiye, hatta **metin işleme** ve **yapay zekâ** uygulamalarına kadar pek çok alanda kullanılmaktadır.

Bu genel kategori içinde, *nedensel akıl yürütme modeli* deyince çoğu zaman **karşı-olgusal analiz yapabilen** bir sistem anlaşılır. Yani model, **gözlenen bir durumu değiştirerek** (örneğin bir hastaya ilaç verip vermeme) sonucun nasıl farklılaşacağını öngörebilmelidir. Bunu başarmak için bazı modeller veriye dayalı **nedensel keşif** yaparak grafik yapısını öğrenir, bazıları deneysel tasarımları taklit eder, bazıları ise doğrudan **karşı-olgusal simülasyonlar** üretir. Örneğin, yakın dönemde büyük dil modellerinin (LLM) bu amaçla kullanımı araştırılmış ve değişken isimlerinden yola çıkarak nedensel grafikleri çıkarabildikleri gösterilmiştir (Tübingen nedensel veri kümesinde GPT-4 %97 doğrulukla ilişki yönünü doğru tahmin etmiştir) ¹¹ . Yine de bu genel modeller, geniş bir kapsamı içerdiği için, belirli bir problem türüne özelleşmiş olmayabilir. İşte **Counterfactual Recurrent Model (CRN)** bu noktada, özellikle *zaman serileri ve ardışık karar problemleri* için geliştirilmiş özel bir nedensel çıkarım modelidir.

Counterfactual Recurrent Model (CRN) Nedir?

Şekil: Karşı-olgusal tekrarlayan ağ mimarisi örneği (R-MSN/CRN). Bu mimaride bir **encoder (kodlayıcı)** RNN katmanı, hastanın geçmiş verileri ve mevcut tedavi bilgisini kullanarak her zaman adımı için **tedaviden bağımsız bir gizli temsil z_t** oluşturur. Ardından bir **decoder (çözücü)** katmanı, bu temsil ve o andaki tedavi girdisine dayanarak bir sonraki adımın beklenen sonucunu \hat{y}_{t+1} tahmin eder ¹² . CRN benzeri modeller, bu sayede farklı tedavi serileri altında gelecekteki olası sonuçları simüle edebilir.

Counterfactual Recurrent Network (CRN), Ioana Bica ve arkadaşları tarafından 2020’de önerilen, özellikle **zaman serilerinde tedavi etkisi çıkarımı** için tasarlanmış bir derin öğrenme modelidir ¹³ . CRN, bir tür **sequence-to-sequence (dizi-çözümleme)** mimarisi olup, *tekrarlayan sinir ağları (RNN/LSTM)* kullanarak **bireysel düzeyde karşı-olgusal sonuçları** tahmin eder ¹³ . Bu model, özellikle sağlık alanında “hangi zaman noktasında, hangi tedaviyi vermeli?” sorusunu yanıtlamak üzere geliştirilmiştir ¹⁴ . Örneğin, bir hastanın geçmiş ölçümlerini ve aldığı tedavileri kullanarak, *farklı bir tedavi uygulanmış olsaydı hastanın durumu zamanla nasıl değişirdi* sorusunu cevaplayabilir.

CRN’in çalışma mantığı, **gözlemsel zaman serisi verisinden öğrenerek** olası müdahalelerin sonuçlarını öngörmeye dayanır. Ancak zaman serilerinde **zamanla değişen karıştırıcılar** (confounders) olduğundan, doğrudan RNN eğitmek yanıltıcı tahminlere yol açabilir. CRN bu sorunu aşmak için **alan adversaryal (domain adversarial) eğitim** kullanarak her zaman adımında “**tedaviye invariant (bağımsız)**” bir gizli temsil oluşturur ¹⁵ . Başka bir deyişle, model her bir zamanda hastanın geçmişinden elde ettiği temsilin o anda seçilen tedaviden bağımsız olmasını sağlamaya çalışır. Bu sayede, geçmiş sağlık durumu ile uygulanan tedavi arasındaki ilişki koparılır ve daha **dengelenmiş bir temsil** elde edilir ¹⁶ . Ardından bu temsil ve mevcut tedavi girdisiyle model, sonraki adımın sonucunu tahmin eder. Bu süreç, her bir zaman adımında tekrarlanarak herhangi bir **tedavi stratejisi** altında geleceğe yönelik bir sonuç yolu (trajectory) simüle edilebilir.

CRN’in getirdiği yenilik, **zaman boyutunda karşı-olgusal tahmin yapabilmesidir**. Geleneksel potansiyel sonuç yöntemleri genellikle tek seferlik tedavi etkisine odaklanırken, CRN ardışık ve çoklu tedavi durumlarını ele alır. Bica ve arkadaşlarının çalışması, simüle edilmiş bir tümör büyümesi senaryosunda CRN’in zamanla değişen karıştırıcılar varlığında bile karşı-olgusal tahmin hatasını azaltabildiğini ve doğru tedaviyi/dozajı seçmede daha başarılı olduğunu göstermiştir ¹⁷ . Kısaca, CRN **kişiselleştirilmiş tedavi planları** önermek için geçmiş veriden öğrenen ve “*eğer bu hasta şu anda alternatif tedavi olsaydı sonucu ne olurdu?*” sorusunu yanıtlayan özel bir nedensel modeldir.

Mimari ve İşleyiş Farkları

Counterfactual Recurrent Model (CRN) ile genel **nedensel akıl yürütme modelleri** arasındaki farkları teknik mimari ve işleyiş açısından şöyle özetleyebiliriz:

- **Temel Yapı:** CRN, adından da anlaşıldığı gibi **tekrarlayan sinir ağı** tabanlıdır. Bir **encoder-decoder RNN/LSTM** mimarisi kullanarak, girişte ardışık verileri işler ve çıktıda yine ardışık tahminler üretir ¹³. Buna karşın birçok genel nedensel model **RNN kullanmak zorunda değildir**. Örneğin, yapısal nedensel modeller bir **DAG üzerindeki yapısal eşitlikler** olarak çalışır, derin öğrenme tabanlı olmayan yöntemler regresyonlar veya istatistiksel karşılaştırmalar kullanabilir. Yani CRN **zaman serilerine özel bir mimari** iken, diğer nedensel modeller problem tipine göre değişik yapılar kullanabilir.
- **Zaman Serisi vs. Statik Veri:** CRN özellikle **uzunlamasına (longitudinal)** veriler içindir. Bir hastanın zaman içindeki çoklu tedavi ve sonuç verilerini kullanır ve geleceğe yönelik uzun bir sonuç dizisi tahmin edebilir ¹³ ¹⁷. Genel nedensel modellerin bir kısmı ise **statik senaryoları** ele alır: Örneğin bir pazarlama kampanyasının tek seferlik etkisini değerlendirmek gibi. Statik modeller her bir birim için tek bir “tedavi vs kontrol” durumu karşılaştırır. CRN ise her zaman adımında yeni bir müdahaleyi hesaba katarak **dinamik tedavi rejimlerini** modelleyebilir.
- **Karşı-Olgusal Tahmin Yöntemi:** CRN, derin ağını eğitirken **karşı-olgusal çıktıları doğrudan** simüle etmeyi öğrenir. Bir kez eğitildikten sonra, örneğin bir hasta için *ilaç A yerine ilaç B verilseydi* diyerek modeli beslediğinizde, CRN bu müdahalenin sonuç serisini tahmin eder. Klasik nedensel modellerde ise genellikle **iki ayrı model/trajektori** karşılaştırması yapılır (tedavi aldı vs almadı) veya **matematiksel çıkarımlar** ile karşı-olgusal hesaplanır. Rubin çerçevesinde bir bireyin karşı-olgusal sonucu gözlemlenmediği için, istatistiksel yöntemlerle ortalama üzerinden tahmin edilir. CRN gibi derin modeller ise *simülatör* gibi davranarak bireysel düzeyde sonuç üretir.
- **Özelleşme ve Esneklik:** CRN, özel olarak **tedavi etkisi çıkarımı** için tasarlanmıştır ve bu amaca dönük optimizasyonlar içerir (örn. adversaryal temsil öğrenimi). Genel nedensel modeller daha geniş kavramları içerir; örneğin bir **nedensel keşif algoritması**, veri setinden sebep-sonuç ağını çıkarmaya odaklanır ama karşı-olgusal tahmin yapmayabilir. Veya bir **nedensel mantık model** (ör. bir bilgi grafiği üzerinde çıkarım yapan) belirli bir bilimsel hipotezi test etmeye odaklanır. CRN ise *öğrenilmiş temsil üzerinden karar kıyaslaması* yapmaya özeldir. Bu yönüyle, CRN’i **nedensel akıl yürütme modelleri ailesinin bir üyesi** fakat belirli bir probleme uyarlanmış bir türü olarak görmek doğru olur.
- **Performans ve Ölçeklenebilirlik:** Derin öğrenme tabanlı CRN, yeterli veri olduğunda karmaşık örüntüleri yakalamada güçlüdür ve zaman serilerinde **uzun dönemli etkileri** modelleyebilir. Ancak RNN tabanlı olması, çok uzun dizilerde veya düzensiz zaman aralıklarında kısıtlar getirebilir. Nitekim 2022 yılında Melnychuk ve ekibi, CRN’in bazı limitlerini gidermek için **Transformer tabanlı** bir model olan *Causal Transformer (CT)*’ı tanıttı; bu model RNN ile Transformer bileşenlerini birleştirerek **uzun vadeli bağımlılıkları** daha iyi yakaladı ve karıştırıcı etkisini azaltmak için yeni bir adversaryal kayıp fonksiyonu kullandı ¹⁸. Genel olarak, nedensel modeller arasında performans kıyaslaması yapılırken, problemin doğası önemlidir: Zaman boyutu içeren dinamik karar problemlerinde CRN ve türevleri üstün performans gösterirken, statik veya tablosal veri problemlerinde daha basit nedensel yöntemler yeterli ve daha yorumlanabilir olabilir.

Açıklanabilirlik ve Yorumlanabilirlik

Nedensel modellerin **açıklanabilir olması**, karar-destek sistemlerinde güvenilirlik açısından çok değerlidir. Bu açıdan CRN ve benzeri derin modeller ile geleneksel nedensel modeller arasında belirgin farklar vardır.

CRN (ve genelde derin karşı-olgusal ağlar), bir **yapay sinir ağı** olduğu için iç yapısı genellikle bir *kara kutu* gibidir. Model parametreleri ve katmanları, insanların kolayca yorumlayamayacağı karmaşık ilişkileri temsil eder. Nitekim literatürde derin öğrenme modellerinin çoğunun **yorumlanabilirlikten yoksun** olduğu, daha ziyade *girdi-çıktı arasındaki korelasyonları* öğrenmeye odaklandığı belirtilmektedir¹⁹. CRN her ne kadar nedensel prensiplerle (dengeleyici temsil, vs.) eğitilse de, tek tek nöronların veya temsillerin anlamı doğrudan açıklanamaz. Bu, modelin bir tahmini *neden yaptığını* tam olarak izah etmeyi zorlaştırır. Dolayısıyla CRN'den elde edilen karşı-olgusal tahminler, **model tabanlı bir simülasyon** olarak kabul edilir; uzmanlar bu tahminlere güvenmek için modelin performans metriklerine dayanmak zorundadır.

Buna karşılık, **yapısal nedensel modeller gibi açıklayıcı yöntemler** daha şeffaftır. Örneğin bir SCM, nedensel grafikteki oklarla hangi değişkenin hangisini etkilediğini net biçimde ortaya koyar. Her bir ok, belirli bir fonksiyon veya eşitlikle tanımlandığından, *"X değişkeni Y'yi şöyle etkiler"* diye açıklanabilir. Karşı-olgusal bir soru sorulduğunda (örn. X faktörünü sabitlemek), SCM bu etkiyi ilgili eşitliği değiştirip yeniden hesaplayarak verir – bu süreç insanlarca takip edilebilir. Benzer şekilde, **Rubin potansiyel sonuç yaklaşımı** ile yapılan analizlerde, örneğin *tedavi uygulansaydı/uygulanmasaydı* gibi iki durumun karşılaştırılması açıkça ifade edilebilir. Yani geleneksel nedensel modeller, **nedensel mekanizmayı** veriyle birlikte sunar; bu da karar vericilerin modele dair içgörü kazanmasını kolaylaştırır.

Ancak, belirtmek gerekir ki **derin nedensel modeller** alanında da açıklanabilirliği artırma yönünde çalışmalar vardır. Örneğin, nedensel etki tahmini yapan derin modellerde *feature importance* (özellik önem skorları) veya *counterfactual explanation* (karşı-olgusal açıklama) teknikleri uygulanarak, modelin hangi girdi değişimine nasıl tepki verdiği anlaşılmaya çalışılır²⁰. Yine de, genel bir kural olarak CRN gibi bir model, **açıklanabilirlikten ziyade tahmin doğruluğuna** odaklanır ve klasik nedensel modellere kıyasla daha az şeffaftır¹⁹. Karar-destek sistemlerinde bu durum, modelin sunduğu önerilerin neden mantıklı olduğunu karar vericilere anlatmayı zorlaştırabilir. Bu nedenle pratikte çoğu zaman derin nedensel modellerin çıktıları, insan yorumunu kolaylaştırmak için ek görselleştirmeler veya basitleştirilmiş kurallarla desteklenir.

Karar Destek Sistemlerine Katkıları

Nedensel akıl yürütme modelleri de, CRN gibi karşı-olgusal derin modeller de **karar destek sistemleri** için çok güçlü araçlardır, ancak katkıları farklı şekillerde ortaya çıkar:

- **CRN ve Benzeri Modellerin Katkısı:** Özellikle **sağlık** ve **kişiselleştirilmiş tedavi** alanında CRN büyük bir boşluğu doldurur. Bir doktor, *"bu hastaya şimdi tedavi A yerine tedavi B'yi versem, uzun vadede hangisi daha iyi sonuç verir?"* sorusunu CRN yardımıyla sayısal olarak inceleyebilir. Bica ve arkadaşlarının çalışmasında vurguladığı gibi, bu model hastanın geçmiş verilerinden öğrenerek **ne zaman müdahale etmek gerektiği** ve **hangi müdahalenin en iyi sonucu vereceği** konusunda öneriler sunabilir¹⁴. Bu, klinik karar destek sistemlerinde hekimlerin veri destekli kararlar almasını sağlar. Yalnızca tıp değil, örneğin **finans** alanında da benzer bir yaklaşım düşünülebilir: Bir müşteriye farklı zamanlarda farklı kampanyalar uygulanırsa tepkisinin nasıl olacağını CRN ile tahmin edip, en iyi pazarlama stratejisini belirlemek mümkün olabilir. Özetle

CRN, **dinamik karar verme** problemlerinde her bir aksiyonun gelecekteki etkisini öngörerek, karar vericilere alternatif senaryolar arasında kıyas yapma imkânı tanır.

- **Genel Nedensel Modellerin Katkısı:** Daha geniş perspektiften bakıldığında, nedensel modeller “**hangi faktörler sonucu etkiliyor ve nasıl?**” sorusuna yanıt verdiği için, stratejik kararlarda vazgeçilmezdir. Örneğin, bir üretim hattında hata oranını azaltmak için nedensel bir model, hatanın kök nedenlerini (makine ayarı mı, operatör eğitimi mi vb.) ortaya çıkarabilir. Bu sayede karar destek sistemi, sadece korelasyonlara bakarak yanlış yönlendirmek yerine, **doğru müdahale noktalarını** işaret eder. Bilimsel araştırmalarda ise nedensel modeller hipotez testini güçlendirir: Bir kimyasal reaksiyonda sıcaklığın arttırılmasının verimi yükseltip yükseltmeyeceği, kontrollü deney yapmadan önce nedensel bir modelle öngörülebilir. Son yıllarda özellikle **sektörel uygulamalarda** derin nedensel modellerin kullanımı artmıştır; örneğin bir inceleme çalışması, endüstride derin nedensel modellerin çeşitli karar problemlerinde başarıyla uygulandığını ve makine öğrenimi ile neden-sonuç analizini birleştirerek daha iyi stratejiler üretildiğini ortaya koymuştur ⁷ ¹⁰ .

Karar destek sistemleri için en kritik katkı, nedensel modellerin **açıklanabilirlik ve güven** getirmesidir. Sadece tahmin yapmak yerine “*neden böyle oldu, farklı yapsak ne olurdu*” sorularını cevaplayabilen sistemler, insan karar vericilerin içgüdülerine yakın bir şekilde çalışır. CRN gibi modeller, doğrudan “ne olurdu” sorusunun cevabını sayısal simülasyonla verse de, altında yatan nedenleri açık etmez. Bunun yerine bir SCM tabanlı sistem, belki daha basit senaryolar için, “A faktörü %5 artarsa B sonucu şu mekanizma ile %2 artar” gibi anlaşılır ilişkiler sunabilir. Bu nedenle, pratik karar destek uygulamalarında çoğu zaman **hibrit yaklaşımlar** benimsenir: Derin karşı-olgusal modellerin sağladığı kesin tahminler, geleneksel nedensel modellerin sağladığı yorumlarla bir arada kullanılır. Böylece hem *isabetli* hem de *güvenilir* karar önerileri üretilebilir.

2024 ve Sonrası: Güncel Araştırma ve Gelişmeler

Nedensel çıkarım ve karşı-olgusal modelleme alanı son birkaç yılda hızlı bir gelişim göstermiştir. 2024 itibariyle literatürde özellikle **derin öğrenme tabanlı karşı-olgusal modellerde** yenilikler dikkat çekmektedir. CRN’in başarılı uygulaması ardından, araştırmacılar bu modeli daha da geliştirmek veya alternatif yaklaşımlar denemek üzere çeşitli çalışmalar yapmıştır:

- **Transformer Tabanlı Modeller:** RNN tabanlı CRN’den sonra, **Transformer** mimarisinin sekans modellemedeki gücünü nedensel çıkarıma uyarlama çalışmaları ortaya çıktı. Örneğin 2022’de bahsedilen *Causal Transformer (CT)* modeli, LSTM ile Transformer katmanlarını bir araya getirerek uzun dönemli etkileşimleri daha iyi öğrenmiştir ¹⁸ . 2024 yılında ise *G-Transformer* adı verilen bir model, tamamen Transformer tabanlı bir çerçevede **g-hesaplaması (g-computation)** yöntemini destekleyerek dinamik tedavi stratejilerinde karşı-olgusal tahmin yapmıştır ²¹ ²² . G-Transformer, ardışık veride **uzun menzilli bağımlılıkları** yakalamada başarılı olmuş ve klasik RNN tabanlı CRN dahil önceki yöntemleri çeşitli simülasyonlar ve gerçek dünya verilerinde geride bırakmıştır ²³ ²² . Bu, CRN paradigmasının Transformer gibi yeni nesil mimarilerle birleşerek daha yüksek doğruluk ve esneklik kazandığını göstermektedir.
- **Sürekli Zaman ve Diferansiyel Modeller:** Gerçek hayatta veriler her zaman düzenli aralıklarla gelmez. 2022’de Seedat ve arkadaşları, **Temporal Normalizing Flows / Neural CDE** yaklaşımlarıyla **düzensiz örneklemli zaman serilerinde** karşı-olgusal tahmin problemini ele almışlardır ²⁴ . *TE-CDE* modeli, kontrol edilen diferansiyel denklemler kullanarak, örneklem zamanlarının aralıklı olmasından kaynaklı hataları azaltmıştır. Yine 2022’de Brouwer ve ekibi **Karşı-Olgusal ODE (CF-ODE)** modelini tanıtmış, bunu 2023’te Hess ve ekibi **Bayesçi Nörel CDE**

(BNCDE) modeliyle geliştirerek **belirsizlik hesabını** da modele entegre etmişlerdir ²⁵ ²⁶ . Bu çalışmalar, CRN'in temel aldığı RNN yaklaşımını farklı açılardan genellemekte; özellikle sağlık gibi kritik alanlarda *tahmin belirsizliğini* hesaplayarak karar destek sistemlerine güvenilirlik katmaktadır.

- **Karşı-Olgusal Öğrenmede Kontrastif ve Temsili Öğrenme:** 2023'te NeurIPS konferansında sunulan bir çalışma, **Counterfactual Contrastive Learning** yöntemini tanıtmış ve uzun vadeli ilişkileri yakalamak için kontrastif yaklaşımlarla karşı-olgusal regresyon yapmıştır ²⁷ . Bu gibi teknikler, modelin karşı-olgusal senaryolar arasındaki ince farkları öğrenmesini teşvik ederek performansı artırmayı amaçlar. Örneğin, aynı hastanın iki farklı tedavi sekansı altındaki sonuçlarını karşılaştırarak öğrenme yapılır ve model, farklı tedavileri ayırt eden önemli özellikler daha iyi kavrar.
- **Büyük Modeller ve Nedensel Akıl Yürütme:** 2024 itibarıyla büyük dil modellerinin nedensel akıl yürütme kabiliyetleri de araştırılmaktadır. GPT-4 gibi modellerin, doğrudan verilere bakmadan değişken isimlerinden nedensel ilişki yönlerini doğru tahmin edebildiği gösterilmiştir ¹¹ . Ayrıca, metin tabanlı senaryolarda karşı-olgusal hikâyeler üretme, çok modlu (metin+görsel) ortamda nedensel çıkarım yapma gibi konular ortaya çıkmıştır. Her ne kadar LLM'ler henüz güvenilir karar destek aracı olarak görülme de, gelecekte nedensel modellerle entegrasyonu söz konusudur. Bu alandaki çalışmalar, bir taraftan derin modelleri **nedensel açıdan zenginleştirmeye**, diğer taraftan nedensel modelleri **dilsel/semantik bilgilerle** desteklemeye odaklanmıştır.
- **Endüstriyel ve Bilimsel Uygulamalar:** Güncel literatürde, nedensel modellerin pratik uygulamalarına dair de önemli yayınlar çıkmaktadır. Örneğin, 2024 yılında yayınlanan kapsamlı bir derleme, **derin nedensel modellerin endüstrideki uygulamalarını** (ör. e-ticaret, finans, sağlık) ele almış ve bu modellerin karar verme süreçlerine somut katkılar sunduğunu vurgulamıştır ⁷ ¹⁰ . Yine 2024'te bir başka çalışmada, **spiking sinir ağları** ile beyin esinli bir nedensel çıkarım modeli geliştirilerek yapay zeka karar süreçlerine nedensellik katılmaya çalışılmıştır (Le Xiao ve ark., 2024). Bu çeşitlilik, CRN gibi belirli bir probleme odaklı modellerin yanı sıra, genel nedensel akıl yürütme konseptinin de geniş bir araştırma alanı olduğunu gösteriyor.

Sonuç ve Değerlendirme

Özetlemek gerekirse, *Counterfactual Recurrent Model (CRN)* belirli bir problem uzayında (zaman serisi verilerinde bireysel tedavi etkileri) nedensel çıkarım yapmak üzere tasarlanmış özel bir derin öğrenme modelidir. Bir **sekans** boyunca farklı müdahalelerin sonuçlarını simüle edebilmesiyle, genel nedensel modeller arasında özgün bir konuma sahiptir. Buna karşılık, *nedensel akıl yürütme modeli* daha genel bir terim olup, **yapısal nedensel modellerden derin ağ tabanlı modellere, bilgi grafiği yaklaşımlarından istatistiksel yöntemlere kadar** pek çok yöntemi içerir. CRN, bu yelpazenin içinde **derin öğrenme + karşı-olgusal çıkarım** kesişiminde yer alır.

Teknik mimari açısından, CRN bir sinir ağıdır (özellikle RNN tabanlı) ve veri güdümlü şekilde nedensel etkiyi öğrenir; genel nedensel modeller ise bazen yapıya dayalı matematiksel formüller veya daha basit istatistiksel yöntemler kullanabilir. **Performans boyutunda**, CRN gibi modeller büyük veri üzerinde güçlü tahminler yapabilir ve karmaşık desenleri yakalayabilir; nitekim CRN türleri, uygun senaryolarda geleneksel yöntemleri bireysel tedavi etkisi tahmininde geride bırakmıştır ⁸ . Ancak **açıklanabilirlik** açısından CRN bir kara-kutu niteliğindeyken, klasik nedensel modeller nedensel ilişkileri açıkça sunarak daha yorumlanabilir ¹⁹ .

Her iki model türü de **karar destek sistemlerine** farklı şekillerde katkı sunar: CRN, özellikle zaman içindeki kararların sonuçlarını öngörerek *proaktif stratejiler* oluşturmada yardımcı olurken, nedensel modeller genel olarak *neden-sonuç bilgisini* ortaya koyarak karar vericinin anlayışını derinleştirir. 2024 ve sonrası çalışmaları, bu iki yaklaşımın da gelişmeye devam ettiğini, hatta zaman zaman birleştiğini (örn. Transformer tabanlı karşı-olgusal modeller, dil modelleri ile nedensel çıkarım entegrasyonu) göstermektedir ^{23 11} .

Sonuç olarak, Counterfactual Recurrent Model ile genel nedensel akıl yürütme modelleri arasındaki fark, birinin **özel amaçlı derin bir simülatör** olması, diğerinin ise **geniş kapsamlı bir nedensel analiz çerçevesi** sunmasıdır. Uygulamada, en iyi sonuçlar çoğu zaman bu yaklaşımların bileşimiyle elde edilir: Derin modellerin gücünden yararlanırken, nedensel çerçevenin prensiplerine bağlı kalmak, hem yüksek performanslı hem de güvenilir ve açıklanabilir karar destek çözümleri geliştirmeyi mümkün kılar.

Kaynaklar: Nedensel ve karşı-olgusal modelleme konusunda derinlemesine bilgi ve en güncel gelişmeler için aşağıdaki akademik çalışmalara başvurulabilir:

- Bica, I. vd. (2020). **"Estimating Counterfactual Treatment Outcomes over Time Through Adversarially Balanced Representations."** ICLR 2020. ^{13 17}
- Li, Z. vd. (2024). **"A survey of deep causal models and their industrial applications."** *Artificial Intelligence Review*, 57(298). ^{7 10}
- Xiong, H. vd. (2024). **"G-Transformer: Counterfactual Outcome Prediction under Dynamic and Time-varying Treatment Regimes."** arXiv preprint arXiv:2406.05504. ^{21 22}
- Melnychuk, K. vd. (2022). **"Causal Transformer for Estimating Counterfactual Outcomes."** NeurIPS Workshop on Causal Representation Learning. ¹⁸
- Borland, D. vd. (2024). **"Causal Reasoning and Visualizations."** *IEEE Computer*, Jan/Feb 2024. ^{3 6}
- **Diğer önemli çalışmalar:** Seedat vd. (2022) TE-CDE modeli, Brouwer vd. (2022) CF-ODE, Hess vd. (2023) BNCDE; Yao vd. (2021) derlemesi nedensel çıkarım ve derin öğrenme; Schölkopf vd. (2021) nedensel temsil öğrenimi; Domingo-Fernández vd. (2022) RPath ilaç keşfi modeli ⁹ – bu çalışmalar literatürde öne çıkan örneklerdir ve konunun derinlemesine anlaşılması için incelenebilir.

^{1 2 4 5 7 8 10 12 18 19 20} A survey of deep causal models and their industrial applications | Artificial Intelligence Review

<https://link.springer.com/article/10.1007/s10462-024-10886-0>

^{3 6} vaclab.unc.edu

https://vaclab.unc.edu/publication/cga_2024_borland/cga_2024_borland.pdf

⁹ KGRDR: a deep learning model based on knowledge graph and ...

<https://pmc.ncbi.nlm.nih.gov/articles/PMC11850324/>

¹¹ arxiv.org

<https://arxiv.org/pdf/2305.00050>

13 14 15 16 17 [2002.04083] Estimating Counterfactual Treatment Outcomes over Time Through Adversarially Balanced Representations

<https://arxiv.org/abs/2002.04083>

21 22 23 [2406.05504] G-Transformer: Counterfactual Outcome Prediction under Dynamic and Time-varying Treatment Regimes

<https://arxiv.org/abs/2406.05504>

24 25 26 arxiv.org

<https://arxiv.org/pdf/2410.08816>

27 [PDF] Causal Contrastive Learning for Counterfactual Regression Over Time

https://proceedings.neurips.cc/paper_files/paper/2024/file/02cef2ae63853724eb99e70721d3bc65-Paper-Conference.pdf