

Nedensel Akıl Yürütme Ağları (Causal Reasoning Networks) ve Çıkarım Güçlendirme Yöntemleri

Nedensel Akıl Yürütme (Causal Reasoning), geleneksel korelasyon temelli yaklaşımların ötesine geçerek **neden-sonuç ilişkilerini** modellemeyi hedefleyen bir yapay zeka alanıdır. Bu alanda geliştirilen **Nedensel Akıl Yürütme Ağları (Causal Reasoning Networks, CRN)** ve benzeri modeller, makine öğrenimi modellerinin **çıkarım gücünü** artırmayı, yani daha güçlü nedensel çıkarımlar yaparak tahmin başarısını iyileştirmeyi amaçlar. Geleneksel büyük dil modelleri veya derin ağlar, eğitim verilerindeki korelasyonları öğrenir; ancak *nedensellik kavramını içsel olarak anlamazlar*. İnsanlar ise *neden-sonuç bilgisini* kullanarak “yangını kül oluşturur, ancak kül yanına neden olmaz” gibi mantıksal çıkarımlar yapar. Benzer şekilde, **Nedensel AI (Yapay Zekada Nedensellik)** yöntemleri, modellerin veri içindeki kalıpların “**neden**” ortaya çıktığını kavramasını ve “*ya böyle olsaydı?*” tarzi karşı-olgusal senaryoları değerlendirmesini sağlar ¹. Bu sayede karar-destek sistemleri daha güvenilir hale gelir, zira modeller hem hızlı örtüyü tanıma yapabilir hem de **nedensel mantıkla** öngörülerini gerçekleştirebilir ² ³. Aşağıda, 2024'ten günümüze literatürde yer alan ve **CRN benzeri çıkarım güçlendirme** yaklaşımı sergileyen önemli yöntemler özetlenmiştir.

Veri Sıpmalarını Gidermek İçin Nedensel Ağlar (LDCRN Örneği)

Doğal Dil İşleme (NLI) için LDCRN modeli, eğitim verilerindeki *yanlı (spurious) korelasyonları* gidererek daha **genelleştirilebilir** çıkışım yapmayı hedefleyen bir nedensel ağı yaklaşımıdır. 2024 yılında sunulan **Label-aware Debiased Causal Reasoning Network (LDCRN)** modeli, önce NLI görevi için bir **nedensel grafik** kurarak cümleler ile etiketler arasındaki gerçek nedensel ilişkileri ve istenmeyen korelasyonları tanımlar ⁴. Ardından, güçlü bir dil modeli (örn. RoBERTa) yardımıyla giriş cümlelerinin etiket üzerindeki **toplam nedensel etkisini** hesaplar. Modelin kilit bileşeni, *etiket bilgisi farkındalığına sahip önyargı modülü*dür; bu modül verideki yanlış korelasyonların etkisini ayrı olarak modelleyip **ince taneli (fine-grained)** şekilde ölçer ⁵. Son aşamada, toplam etkiden bu yanlış etkinin çıkarılmasıyla **düzeltilmiş nedensel etki** elde edilir ve model, kararını bu düzeltilmiş etkiye göre verir. Yapılan deneyler, MultiNLI gibi standart veri kümelerinde LDCRN'nin bu yaklaşımıyla üstün performans sergilediğini, insan tarafından derlenmiş zorlayıcı test setlerinde dahi **genel başarımı artırdığını** göstermiştir ⁶. Bu sonuçlar, **nedensel çıkışım güçlendirmesi** ile model önyargılarının azaltılabilceğine ve tahmin doğruluğunun iyileştirilemeyeceğine dair önemli bir kanıt sunmaktadır.

Çok Modlu Nedensel Akıl Yürütme (Video-Metin Eşleme Örneği)

Korelasyona dayalı derin öğrenme modelleri, farklı modaliteler (ör. video ve metin) arasındaki ilişkilerde genellikle *yansıma (confounding) etkileri* tam çözemezdir. **2025 yılında Lan ve Lv tarafından önerilen Nedensel Dikkat Transformatörü (Causal Attention Transformer)** mimarisini, video-metin eşleme görevinde bu sorunu gidermek üzere tasarlanmıştır ⁷. Bu yöntemde, öncelikle video ve altıya verisindeki performansı etkileyen tüm yan etkenlerin veri setinden kaynaklandığı varsayılar ve görevde uygun bir **Yapısal Nedensel Model (Structural Causal Model)** oluşturulur ⁸. Bu nedensel grafiğe dayalı olarak, eğitim sırasında *front-door* kriterine benzer müdahaleler yapılarak veri seti önyargılarının modeli yanıltması engellenir ⁹. Model mimarisinin kalbinde, **Nedensel Dikkat Transformatörü birimleri** bulunur; bu birimler video klipleri ile bunlara ait metin arasında nedensel olarak ilişkili özelliklerini öğrenir. Özellikle, klasik dikkat mekanizmasının ürettiği benzerlik skorları yerine, model *neden-*

sonuç olasılıkları hesaplayarak video ile metin arasındaki eşleşmeyi değerlendirir ⁷. Üç farklı video-metin veri setinde (MSR-VTT, MSVD, LSMDC) yapılan deneyler, bu nedensel çıkarım ağı tabanlı yaklaşımın önceki yöntemlere kıyasla belirgin bir başarı artışı sağladığını göstermiştir ¹⁰. Bu çalışma, **çok modlu karar-destek sistemlerinde** nedensel akıl yürütmenin performansı yükseltebileceğine iyi bir örnek teşkil etmektedir.

Finans ve Karar Destek Alanında Nedensel İlişki Keşfi (CausalStock Örneği)

Finansal tahmin ve karar destek sistemlerinde, değişkenler arası **yönlü ilişkiyi** (bir hissenin diğerine etkisi gibi) yakalamak tahmin başarısını artırabilir. 2024 NeurIPS konferansında sunulan **CausalStock** modeli, haber metinleri ve piyasa verilerinden **nedensel keşif** yaparak çoklu hisse senedi hareketi tahminini iyileştiren bir yaklaşımdır ¹¹. CausalStock mimarisi iki ana bileşene sahiptir: (1) *LLM tabanlı Gürültü Giderimli Haber Kodlayıcı* – finans haberlerindeki gürültüyüfiltrelemek için büyük bir dil modelinin değerlendirme yeteneğini kullanarak haberlere puan verir ve **temiz temsiller** oluşturur ¹² ¹³; (2) *Gecikme Bağımlı Nedensel Keşif Modülü* – zaman serisi verilerdeki stoklar arası nedensel etkileşimleri yakalar. Bu modül, her bir hisse senedi arasındaki **nedensel yönlü bağları** öğrenebilme için zaman gecikmesini de hesaba katan bir yöntemle *nedensel grafik* (*DAG*) dağılımı çıkarır ¹¹ ¹⁴. Elde edilen **nedensel grafik**, fonksiyonel nedensel modelleme (FCM) yaklaşımları ile entegre edilerek tahmin aşamasında kullanılır ¹⁵. Sonuçta CausalStock, aynı anda hem **hisseler arası nedensel ilişkileri keşfedip modelleyerek** hem de haber bilgisini gürültüden arındırarak, çeşitli veri setlerinde **daha yüksek doğrulukta tahminler** yapmayı başarmıştır ¹⁶ ¹⁷. Bu yaklaşım, finansal karar-destek sistemlerinde ve diğer zaman serisi tahmin problemlerinde, **nedensel öğrenimin** korelasyon temelli yöntemlere kıyasla önemli avantajlar sunabileceğini göstermektedir.

Bilimsel Modelerde Nedensel Kısıtlar ve Fiziksel Tutarlılık

Bilimsel modelleme ve mühendislik alanlarında, **fizik yasaları ve nedensellik** gözetilmeden eğitilen kara-kutu derin öğrenme modelleri, fiziksel olarak tutarsız sonuçlar üretебilir. Bu sorunu ele almak için geliştirilen **Nedensel Fizik-Katılımlı Derin Öğrenme Mimarисinde** (Adombi & Chesnaux, 2024), makine öğrenimi modellerine *nedensel ilişki kısıtları* entegre edilmiştir ¹⁸. Temel fikir, bir fiziksel sistemin değişkenleri arasındaki neden-sonuç önceliklerini model içeresine kısıtlar olarak koymak ve böylece modelin bu ilkelere uymasını sağlamaktır. Örneğin, yeraltı suyu seviye simülasyonunda, yağış → yeraltı suyu beslemesi → seviye değişimi şeklindeki nedensel zincirin gözetilmesi hedeflenmiştir. Adombi ve arkadaşlarının önerdiği mimaride, sıradan bir 1D-CNN modeli ile karşılaştırılan iki *fiziksel bilgiyle zenginleştirilmiş model* bulunur: Biri önceki çalışmadan alınan temel PIML (Physics-Informed ML) modelidir (H-Lin), diğer ise **yeni nedensel kısıtlı mimarı** (H-LinC). Yapılan deneyler, saf derin öğrenme modeli (1D-CNN) en düşük fiziksel tutarlılığa sahip olsa da en yüksek hatasızlığa ulaştığını, ancak yeni önerilen H-LinC modelinin **hem fiziksel nedensellik kurallarına uyup** hem de önceki nedensel modelden daha iyi performans gösterdiğini ortaya koymuştur ¹⁹. Özellikle H-LinC, eski nedensel model H-Lin'e kıyasla **tahmin doğruluğunu yükseltirken** nedensel prensiplere sadık kalabilmiştir ²⁰. Bu çalışma, bilimsel karar destek modellerinde nedensel kısıtların entegre edilmesinin, modeli kısıtlamak bir yana, doğru uygulandığında **modelleme başarımını da artıracabileceğini** göstermektedir ²¹ ²².

Sağlıkta Karar Destek için Nedensel Öneri Sistemleri

Karar destek sistemlerinin önemli bir kullanım alanı olan sağlık teknolojilerinde de nedensel çıkarım odaklı yaklaşımlar öne çıkmaya başlamıştır. **Dijital mental sağlık** alanında 2024 sonunda önerilen

Causal AI Recommendation System (CAIRS) buna iyi bir örnektir. CAIRS, uzman bilgisi ve gözlemsel verileri kullanarak bir **nedensel model** öğrenir; daha sonra bu modeli kullanarak farklı müdahalelerin (ör. belirli bir terapi uygulanırsa sonucu ne olur gibi) sonuçlarını *simüle eder*²³. Bu sayede, olası tedavi veya müdahale seçeneklerinin **karşı-olgusal senaryoları** değerlendirebilir ve en olumlu sonucu verecek seçenek belirlenebilir. Örneğin, bir dijital sağlık platformunda CAIRS, bir danışanın verilerine dayanarak "X tedavisi uygulansaydı depresyon skoru nasıl değişirdi?" sorusunu sorup, farklı tedavi ihtimallerinin sonuçlarını karşılaştırarak en etkili müdahaleyi önerir. Bu yaklaşım, geleneksel öneri sistemlerinden farklı olarak "**neden-sonuç**" odaklıdır ve özellikle sağlık gibi yüksek riskli karar alanlarında daha güvenilir *karar-destek* sağlayabilir. Nitekim, **nedensel AI**'n genel avantajlarından biri de önyargıları azaltması ve *adil kararlar* desteklemesidir: Değişkenler arasındaki ilişkileri açıkça modelleyerek, kararları etkilemeyen ancak korelasyon yaratan yan etkenleri tespit edip etkisini gidermek mümkün olur²⁴. Bu da özellikle tıp ve finans gibi alanlarda, nedensel çikarsama yöntemlerinin daha şeffaf, açıklanabilir ve **etkili tavsiyeler** sunmasına imkan tanır.

Büyük Modellerde Nedensel Akıl Yürütmeye Eğilimleri

2024 ve sonrasında, büyük ölçekli yapay zeka modellerinin (özellikle **Büyük Dil Modellerinin**) nedensel akıl yürütme yeteneklerini artırmak da araştırmacıların öncelikli hedeflerinden biri olmuştur. Örneğin, son dönemdeki bir derleme çalışmasında, mevcut büyük dil modellerinin aslında **nedensel çıkarım yeteneğinin sınırlı olduğu**, çünkü eğitim süreçlerinde neden-sonuç ayrimından ziyade dilsel korelasyonlara odaklandıkları vurgulanmıştır²⁵. Bu kısıtı aşmak için literatürde çeşitli yöntemler görülmektedir: *nedensel bilgisayar oyunları* veya *bulmacalarla* modellenin eğitilmesi, *girdi-çıktı çiftlerinde nedensel ipuçları barındıran özel veri kümeleriyle ince ayar (fine-tuning)*, veya *model çıktılarının harici nedensel araçlarla* (ör. *nedensel grafik hesaplayıcılar*) desteklenmesi gibi teknikler önerilmektedir²⁶. Amaç, büyük modellerin sadece dilsel tutarlılığı değil, aynı zamanda **gerçek dünyadaki neden-sonuç ilişkilerini** de içselleştirmesini sağlamaktır. Nitekim, tıp ve ekonomi gibi alanlardaki uygulamalarda salt korelasyona dayanan modeller yetersiz kaldığından, bu modellerin **nedensel mantık yürütme** becerisinin geliştirilmesi gerektiği vurgulanmaktadır^{27 28}. Geleceğe dönük çalışmalar, multimodal (örn. görsel-işitsel) ortamlarda nedensel akıl yürütme, modellerin kendi kendine nedensel çıkarım yapmayı öğrenmesi ve etik açıdan tutarlı nedensel kararlar alabilmesi gibi konulara odaklanmaktadır²⁹. Özette, CRN ve benzeri yaklaşımalar başlangıçta özel görevler için geliştirilmiş olsa da, günümüzde **genel amaçlı yapay zeka sistemlerinin** de vazgeçilmez bir parçası haline gelmektedir.

Sonuç ve Değerlendirme

CRN benzeri çıkarım güçlendirme modelleri, yapay zekanın karar verme mekanizmalarını *insana daha yakın bir biçimde* güçlendirmeyi hedefleyen yenilikçi yaklaşımlardır. Karar-destek sistemleri ve bilimsel modelleme alanlarında, bu yöntemlerin sağladığı en büyük kazanım, "**neden?**" sorusunu veri odaklı bir şekilde yanıtlayabilmeleridir. 2024 ve 2025 yıllarında yayımlanan saygın çalışmalar, nedensel grafikleri derin öğrenmeye entegre ederek önyargıları gidermenin (LDCRN ile), farklı veri modaliteleri arasında nedensel ilişkiler yakalamanın (video-metin nedensel dikkat modelleri ile) ve zaman serisi/finans verilerinde yönlü etkileşimleri öğrenmenin (CausalStock gibi) **tahmin başarımını belirgin ölçüde artırdığını** ortaya koymuştur^{7 16}. Benzer şekilde, fiziksel ilkelere nedensel kısıtlar şeklinde bağlı kalan mimariler, model çıktılarının hem güvenilirliğini hem de doğruluğunu yükseltebilmektedir¹⁹. Sağlık ve benzeri alanlarda, nedensel AI destekli sistemler, "Bu müdahale uygulansa ne olurdu?" sorusunu cevaplayarak daha etkin öneriler sunmaya başlamıştır^{1 23}. Tüm bu gelişmeler, nedensel akıl yürütmenin yapay zeka modellerinde sadece bir açıklanabilirlik unsuru değil, aynı zamanda **performansı da artırın** bir bileşen olabileceğini göstermektedir. Sonuç olarak, 2024 sonrası literatür, derin öğrenme ve nedensel çıkarımın birleşimiyle oluşan bu alanda hızlı bir ilerlemeye işaret etmekte;

geleceğin karar-destek ve tahmin sistemlerinin, “**sebep-sonuç**” odaklı düşünebilen modeller üzerine inşa edileceğinin sinyallerini vermektedir.

Kaynaklar: Bu yanıt içerisinde kullanılan bilgilerin tümü, 2024 ve 2025 yıllarında yayımlanan hakemli makaleler, saygınlı konferans bildirileri ve arXiv gibi ön baskı kaynaklarından derlenmiş olup ilgili cümlelerin sonunda **[kaynak numarasıtsatır aralığı]** biçiminde referans olarak sunulmuştur. Bu sayede, okurlar hem ileri okumalar yapabilir hem de belirtilen yaklaşımın orijinal çalışmalarına doğrudan erişebilirler. [1](#) [7](#) [5](#) [19](#) [11](#) [23](#)

[1](#) [2](#) [3](#) [24](#) Causal AI: the revolution uncovering the 'why' of decision-making | World Economic Forum

<https://www.weforum.org/stories/2024/04/causal-ai-decision-making/>

[4](#) [5](#) [6](#) Label-aware debiased causal reasoning for Natural Language Inference | OpenReview
<https://openreview.net/forum?id=x3beMcIy7M>

[7](#) [8](#) [9](#) [10](#) (PDF) Causal Attention Transformer for Video Text Retrieval
https://www.researchgate.net/publication/391189880_Causal_Attention_Transformer_for_Video_Text_Retrieval

[11](#) [12](#) [13](#) [14](#) [15](#) [16](#) [17](#) proceedings.neurips.cc
https://proceedings.neurips.cc/paper_files/paper/2024/file/54d689d58fe54c92aee2d732fc49fca8-Paper-Conference.pdf

[18](#) [19](#) [20](#) [21](#) [22](#) A New Causal Physics-Informed Deep Learning Architecture to Improve Model Performance in Groundwater Level Simulation by Adoubi Vincent De Paul ADOMBI, Romain Chesnaux :: SSRN
https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4829861

[23](#) CAIRS: A causal artificial intelligence recommendation system for ...
<https://www.medrxiv.org/content/10.1101/2024.11.11.24317126v2.full-text>

[25](#) [26](#) [27](#) [28](#) [29](#) A Survey on Enhancing Causal Reasoning Ability of Large Language Models
<https://arxiv.org/html/2503.09326v1>