

# Nedensel Çıkarım, Karar Destek Sistemleri ve Tahminleme: Kullanım Amaçları ve Güncel Gelişmeler

## Giriş

Yapay zekâ (YZ) modelleri çeşitli amaçlarla kullanılmakta ve farklı **kullanım modelleri** (use-case) altında sınıflandırılmaktadır. Bu raporda, özellikle **nedensel çıkarım**, **karar destek sistemleri** ve **tahminleme** (öngörü) gibi modellerin kullanım amaçlarını ve benzer diğer kullanım modellerini inceliyoruz. Her bir kategori için teknik yaklaşımlar, mimariler ve uygulama örneklerine değinilecek; ayrıca 2024 sonrası dönemde bu alanlardaki güncel gelişmeler, akademik çalışmalar ve trendler, hakemli makale ve saygın konferans bildirilerine dayanarak özetlenecektir.

## Nedensel Çıkarım (Causal Inference)

**Nedensel çıkarım**, veri içindeki nedensellik ilişkilerini (sebep-sonuç bağlarını) ortaya çıkarmayı hedefleyen YZ yaklaşımlarını ifade eder. Amaç, salt korelasyonların ötesine geçerek *“bir faktördeki değişimin diğerini nasıl etkilediğini”* belirlemektir. Bu sayede klasik gözlemsel veriye dayalı modellerin aksine *“ne olsa ydi”* türü senaryolar değerlendirilebilir; yani belirli bir eylemin etkileri modellenabilir. Örneğin pazarlamada bir promosyon kampanyasının satışlara etkisini veya sağlıkta bir ilacın hastalık seyrine etkisini gerçekten anlamak, nedensel modeller ile mümkündür. Nitekim salt geçmiş veriye bakarak yapılan makine öğrenimi tahminleri, eylemlerin sonucunu modellemede yetersiz kalabilir ve yanlış kararlara yol açabilir. Nedensel çıkarım yöntemleri, bu boşluğu doldurarak karar vericilerin farklı müdahalelerin sonuçlarını öngörmesine olanak tanır. Bu nedenle nedensellik analizi, bilimsel araştırmalarda ve yüksek riskli uygulamalarda (ör. sağlık, ekonomi, politika) giderek kritik bir rol üstlenmektedir. Özellikle sağlık hizmetleri, finans ve deneysel bilimlerde *“korelasyon değil, neden-sonuç ilişkisi”* arayışı hayati önemdedir.

Nedensel çıkarım için geliştirilmiş iki temel teorik çerçeve *yapısal nedensel modeller (structural causal models)* ve *potansiyel sonuçlar (potential outcomes)* yaklaşımlarıdır. Judea Pearl’ün geliştirdiği yapısal nedensel modelleme, grafiksel modeller ve do-hesabı ile nedensel etkiyi tanımlarken Donald Rubin’in potansiyel sonuçlar çerçevesi ise istatistiksel deney tasarımına dayanır. Bu geleneksel yöntemler başarısını kanıtlasa da insan uzmanlığı, mantıksal akıl yürütme ve genel bilgi gibi konularda halen insan muhakemesinin gerisinde kalabilir. Ayrıca çoğu klasik nedensel yöntem, genellikle yapılandırılmış (tabular) veriye odaklanmıştır; doğal dil gibi yapısal olmayan verilerde nedensellik analizi zorluklar barındırır. Son dönemde büyük dil modellerinin (LLM’ler) yükselişi ile, YZ alanında nedensel çıkarım problemlerine yeni fırsatlar doğmuştur. 2025 yılında yayınlanan bir çalışma, büyük dil modellerinin *farklı nedensellik düzeylerindeki* görevler için nasıl kullanılabileceğini kapsamlı biçimde incelemiştir. LLM’lerin, geleneksel nedensel analiz yöntemlerini geliştirmeye yardımcı olabileceği; insanın çıkarım sürecine benzer şekilde bilgi ve akıl yürütmeyi entegre ederek nedensel çıkarım görevlerinde ümit vadettiği gösterilmektedir. Özellikle doğal dil işleme alanında LLM tabanlı yaklaşımların, klinik metinler gibi yapılandırılmamış metinlerde gizli nedensel ilişkileri ortaya çıkarmada yeni ufuklar açtığı vurgulanmaktadır.

Teknik mimari açıdan da nedensel çıkarım alanında önemli gelişmeler yaşanmaktadır. Klasik yöntemler (örn. **PC, LiNGAM, DAG tabanlı sürekli optimizasyon yaklaşımları**) yanında derin öğrenme tabanlı **nedensel keşif** yöntemleri ortaya çıkmıştır. Özellikle geniş ölçekli veri setlerinde nedensel ilişkileri öğrenmek için sinir ağlarıyla entegre yöntemler dikkat çekmektedir. Örneğin 2023 yılında biyomedikal alanda sunulan bir çalışma, **Kançal ve Grafik Sinir Ağları (CNN+GNN)** bileşimini kullanan derin bir mimariyle binlerce değişken arasındaki nedensel bağlantıları öğrenebilmeyi göstermiştir. Bu mimari, yüksek boyutluluk, gürültü ve sınırlı veri koşullarında dahi etkili şekilde değişkenler arası nedensel okları keşfedebilmiştir. Özellikle genomik verilerde kısmi neden-sonuç bilgileriyle başlanıp geriye kalan tüm değişkenler arasındaki ilişkileri genelleyen bir ağ yapısı kurulduğu rapor edilmiştir. Sonuçta, binlerce moleküler özellik içinde yeni nedensel ilişki adayları ortaya çıkarılmış ve bunlar bağımsız deneylerle doğrulanmıştır. Bu tür derin **nedensel öğrenme** yaklaşımları, büyük ölçekli biyoloji gibi alanlarda *gizli nedensel ağların* keşfine imkân tanımakta ve bilimsel keşfi hızlandırmaktadır. Özetle, nedensel çıkarım modelleri karar destek amaçlı olarak **“what-if”** analizlerine güç verirken, son çalışmalar LLM entegrasyonu, derin mimariler ve ölçeklenebilir nedensel keşif teknikleriyle bu alanda önemli ilerlemeler kaydetmiştir.

## Karar Destek Sistemleri (Decision Support Systems)

**Karar destek sistemleri**, insan karar vericilere karmaşık problemleri çözmede yardımcı olmak üzere tasarlanan YZ tabanlı araçlardır. Bu sistemler genellikle veriye dayalı içgörüler, tahminler veya öneriler sunarak kullanıcının daha bilinçli ve tutarlı kararlar almasını hedefler. Karar destek modellerinin temel kullanım amacı, çok miktarda veriyi, analitiği ve modeli harmanlayarak *insan aklının erişebileceği özet bilgi* veya *eylem önerileri* üretmektir. Bu bağlamda, karar destek sistemleri *önerici sistemler*, *tanı destek sistemleri* veya *yönetim bilgi sistemleri* şeklinde farklı görünüm alabilir. Örneğin sağlıkta **klinik karar destek** araçları hekimlere tanı ve tedavi önerileri sunabilir; finans sektöründe YZ destekli sistemler yatırım kararları veya risk yönetiminde tavsiyeler üretebilir; imalatı ise tedarik zinciri optimizasyonu için karar destek analizleri yapılabilir.

YZ'nin insan karar süreçlerine entegrasyonu pek çok alanda yeni bir **insan-YZ işbirliği paradigması** oluşturmuştur. Bu paradigmada makine öğrenimi modelleri belirli bir problem hakkında tavsiyeler, tahminler veya açıklamalar sunarken, nihai kararı insan vermeye devam eder. Örneğin adalet sisteminde suç tekrarı riskini değerlendiren algoritmalar veya bankacılıkta kredi onayını destekleyen yapay zekâ modelleri, karar vericiye bir *öngörü* veya *puan* sağlar; ancak sorumlu kişi bu bilgiyi uygun gördüğü şekilde yorumlayarak karara varır. Karar destek sistemlerinin etkinliği, bu insan-makine etkileşiminin ne kadar verimli ve güvenilir olduğuna bağlıdır. Son araştırmalar maalesef kullanıcıların çoğu zaman YZ tavsiyelerini ya *gereğinden fazla güvenerek sorgusuz benimsediğini* ya da *yeterince güvenmeyip faydalanamadığını* göstermektedir. Bu dengesiz durum, ya YZ hatalarında körü körüne yanlış kararlar alınmasına (overreliance) ya da YZ'nin doğru önerilerinin göz ardı edilmesine (underreliance) yol açabilmektedir. **Güvenilir ve anlaşılabilir YZ** tasarımı bu nedenle kritik bir konudur.

Güncel yaklaşımların önemli bir yönü, **açıklanabilir yapay zekâ (XAI)** tekniklerinin karar destek sistemlerine entegre edilmesidir. Kullanıcıların YZ'nin önerilerine **doğru seviyede güven** duyması için, model çıktıları açıklayan arayüzler geliştirilmektedir. Örneğin bir kredi risk modeli, bir başvurunun reddi için *“gelir düzeyi düşük olduğu için risk yüksek”* gibi bir sebep sunabilir. Ancak klasik XAI yöntemleri genelde modelin iç parametrelerine dayalı *post-hoc* açıklamalar üretir ve bu açıklamaları yorumlamak kullanıcılara zor gelebilir. Bu noktada, son dönemde büyük dil modellerinin sağladığı doğal dil açıklama imkânları devreye girmektedir. 2025'teki bir çalışma, LLM tabanlı bir “ikinci danışman” yaklaşımı önererek AI karar önerilerinin her bir özelliğini doğal dilde analiz etmeyi denemiştir. Bu sistemde, asıl karar tavsiyesini veren birincil YZ modelinin yanı sıra, bir LLM modeli kararın nedenlerini insan dilinde özetleyerek kullanıcının önüne sunar. Örneğin bir mahkûmun tahliye kararını destekleyen YZ modeli için LLM, *“sanığın daha önce ciddi suçtan hüküm giymesi tekrar suç işleme riskini artırıyor olabilir”* şeklinde

anlaşılır bir yorum üretebilmektedir. Bu sayede LLM, bir **"ikinci danışman"** gibi hareket ederek insan karar vericinin hem YZ önerisini daha iyi anlamasını hem de kendi iç görüşleriyle YZ tavsiyesini eleştirel biçimde harmanlamasını sağlamaktadır. Yapılan deneyler, uygun biçimde sunulan LLM destekli analizlerin, insanlar ile YZ modelleri arasındaki işbirliğini güçlendirerek daha dengeli bir güven düzeyi oluşturabildiğini göstermektedir.

Karar destek sistemlerinin mimarileri, genellikle **model + arayüz + insan** şeklinde üç bileşeni içerir. YZ modeli veri analizi veya optimizasyon yaparak bir sonuç üretir; arayüz bu sonucu ve varsa açıklamalarını kullanıcıya sunar; kullanıcı da alan bilgisini ve konteksini katarak kararı alır. Son yıllardaki gelişmeler, model tarafında derin öğrenme ve bilgi grafiği gibi güçlü araçların kullanımını artırırken arayüz tarafında da doğal dil etkileşimi (sohbetbotları, sanal asistanlar) yaygınlaşmaktadır. Örneğin, **LLM tabanlı klinik asistanlar**, doktorlarla sohbet ederek hasta durumu hakkında öneriler sunabilmekte; böylece klasik kural tabanlı karar destek araçlarından daha esnek bir deneyim sağlanmaktadır. Ancak bu güçlü sistemlerin *güvenilirlik, şeffaflık ve düzenleyici uygunluk* konuları da ciddi araştırma ve yatırım gerektirmektedir. Sonuç olarak, karar destek sistemleri alanında güncel çalışmalar, **insan-merkezli tasarım, açıklanabilirlik ve güvenilir YZ** etrafında yoğunlaşmaktadır. Hedef, YZ'yi *karar vericinin akıllı bir yardımcısı* haline getirerek tıp, finans, yönetim gibi alanlarda daha isabetli ve hızlı karar süreçleri oluşturmaktır.

## Tahminleme (Öngörü Modellemesi)

**Tahminleme**, geçmiş verilerden öğrenerek geleceğe dair öngörülerde bulunmayı amaçlayan yapay zekâ modellerini kapsar. Bu kategori genellikle **zaman serisi tahmini** (forecasting), **regresyon modellemesi** veya genel anlamda *"predictive analytics"* olarak anılır. Tahminleme modellerinin temel kullanım amacı, gelecekteki koşullar hakkında *karar alıcılar için kritik bilgiler* sağlamaktır. Örneğin ekonomik göstergelerin öngörüsü, satış talebi tahmini, hava durumu veya iklim projeksiyonları, makine arıza tahmini (prediktif bakım) gibi uygulamalar hep bu sınıfa girer. Öngörü modelleri, stratejik planlama ve kaynak yönetimi için kilit önem taşır; zira belirsizliği azaltarak **veriye dayalı karar alma** süreçlerini güçlendirir.

Tahminleme alanı, geleneksel istatistiksel yöntemlerden başlayarak son yıllarda derin öğrenmeye uzanan geniş bir yelpazede evrim geçirmiştir. **ARIMA, Holt-Winters** gibi klasik zaman serisi modelleri veya **regresyon, karar ağaçları, SVR** gibi makine öğrenimi teknikleri uzun süre alanın belkemiğini oluşturmuştur. 2010'ların sonlarından itibaren ise **Yapay Sinir Ağları** yoğun biçimde öngörü problemlerine uygulanmaya başlandı. İlk aşamada tek bir veri kümesine özel eğitilen **RNN/LSTM** veya **CNN** tabanlı modeller popüler oldu. Ancak her bir görev için ayrı model eğitme yaklaşımı, büyük ölçekli uygulamalarda sınırlı kaldı. Yeni eğilim, **Transformer** mimarisi gibi modellerle *uzun dönemli bağımlılıkları* yakalayabilen, gerektiğinde çok değişkenli ve karmaşık yapıları öğrenebilen mimarielere yönelmektir. Transformerlarda yer alan **dikkat mekanizması**, uzun zaman aralıklarındaki ilişkileri etkin biçimde modelleyebildiği için finansal zaman serilerinden hava durumu verilerine kadar pek çok alanda umut vadetmiştir. Nitekim Transformer tabanlı modeller, enerji talebi, satış tahmini gibi problemler üzerinde başarılı sonuçlar vermiştir. Bununla birlikte, son araştırmalar ilginç bir şekilde bazı basit yaklaşımların (ör. yalnızca lineer katmanlar içeren modellerin) dahi karmaşık derin modelleri belirli durumlarda geride bırakabildiğini ortaya koymuştur. Özellikle "D-Linear" gibi basit lineer modellerin, bazı veri setlerinde sofistike transformer mimarilerini aştığı rapor edilmiştir. Bu durum, **zaman serisi modellemesinde mimari çeşitliliğin önemine** işaret etmektedir. Artık araştırmacılar, her probleme aynı mimariyi uygulamak yerine, verinin özelliğine göre farklı mimarileri (CNN, RNN, Transformer, hibrit modeller vb.) denemektedir. Bu sayede alanda adeta bir **"mimari rönesans"** yaşandığı ve birbirinden farklı yaklaşım ve birleşimlerin incelendiği belirtilmektedir. Örneğin bazı güncel çalışmalar **difüzyon modelleri** veya **melez (hybrid) modeller** ile öngörü yapmaya çalışmakta, bazıları ise **çok modelli (multimodal)** veya **nedensel** bilgileri de tahmin sürecine katmaktadır.

2024 ve sonrasında öne çıkan bir diğer eğilim, **geniş kapsamlı (foundation) zaman serisi modelleri** geliştirmektir. Nasıl ki dil veya görüntü işlemede devasa modeller farklı görevlere uyarlanabiliyorsa, zaman serilerinde de *evrensel tahmin modelleri* fikri doğmuştur. **“Universal forecasting”** adı verilen bu yaklaşım, tek bir büyük modeli yüzlerce farklı zaman serisi veri kümesi üzerinde ön-eğitimden geçirerek her tür tahmin görevine uyarlanabilecek genel bir öğrenme sağlama fikridir. 2024’te yayınlanan bir çalışmada **“Moirai”** adlı bir Transformer türevi model, dokuz farklı alandan derlenen devasa bir arşivde (27 milyar veri noktası) ön eğitime tabi tutulmuştur. Bu model, eğitildikten sonra *hiç görmediği* zaman serilerinde bile (sıfır-atış, zero-shot) makul tahminler yapabilmiş ve özel olarak o veri için eğitilmiş modellerle yarışabilmiştir. Bu sonuç, gelecekte **“bir model, tüm tahminler”** yaklaşımının mümkün olabileceğine işaret etmektedir. Aynı çalışma, evrensel model geliştirmede karşılaşılan bazı zorluklara (farklı örneklem sıklıkları, değişen değişken sayıları, veri kümeleri arasında dağılım farkları gibi) yönelik mimari çözümler de önermektedir. Örneğin model, *maskelenmiş kodlayıcı tabanlı* bir tasarımla her bir veri kümesinin kendi özelliklerini öğrenirken genelleştirici bir temsil oluşturmaya başlamıştır.

Tahminleme alanındaki bu çeşitlilik, **yansıma (backcasting) + öngörü (forecasting)** gibi birleşik modellerden, **mevsimsellik-trend ayırıştırma** yaklaşımlarına; **derin öğrenme + istatistiksel model hibritlerinden, çok ölçekli transformer ağlarına** kadar uzanmaktadır. Ayrıca, **temel modeller (foundation models)** kavramı tahminlemenin ötesinde iklim modellemesi gibi bilimsel simülasyonlarda da kullanılmaya başlanmıştır (aşağıdaki bölümde ele alınmıştır). Özetle, tahminleme için YZ modelleri; iş dünyasından bilime pek çok alanda geleceğe dair öngörüler sunarak karar verme süreçlerini desteklemektedir. Son yayınlar, bu alanda mimari çeşitlenme ve büyük ölçekli modeller ile performans sınırlarının zorlandığını, ancak verinin doğasına uygun model seçiminin kritik olmaya devam ettiğini ortaya koymaktadır.

## Bilimsel Modelleme ve Simülasyonda Yapay Zekâ

YZ modellerinin önemli bir kullanım alanı da **bilimsel modelleme, simülasyon** ve **hesaplamalı bilim** alanlarıdır. Bu kapsamda YZ, karmaşık fiziksel sistemleri modellemek, deneysel verilerden bilimsel keşifler çıkarmak veya yüksek maliyetli simülasyonları hızlandırmak için kullanılmaktadır. Örneğin iklim biliminde, hesaplamalı akışkanlar dinamiğinde, malzeme tasarımında veya biyolojik sistemlerde yapay zekâ destekli modellere giderek daha fazla başvurulmaktadır. Bu alandaki hedef, *fiziksel ilkelerle veriye dayalı öğrenmeyi bir araya getirerek* hem hesaplama verimini artırmak hem de yeni öngörüler elde etmektir.

Son yıllarda **Fizik-Destekli Sinir Ağları (Physics-Informed Neural Networks, PINNs)** bu kesişimin popüler bir örneği haline gelmiştir. PINN’ler, diferansiyel denklemleri ve fizik yasalarını doğrudan kayıp fonksiyonuna entegre ederek, az sayıda ölçüm verisiyle bile fiziksel sistemleri çözebilen derin öğrenme modelleridir. 2017’de tanıtıldığından bu yana PINN yaklaşımı bilimsel yapay zekâ alanında önemli bir araç haline gelmiştir; adi veya kısmi diferansiyel denklemleri çözmede verimli sonuçlar verdiği gösterilmiştir. 2024 itibarıyla PINN eğitiminde çeşitli iyileştirmeler kaydedilmiştir: ağ mimarilerinin geliştirilmesi, adaptif ağ ağırlıklandırma teknikleri, bölgeye ayrılmış (domain decomposition) çözümler ve aktivasyon fonksiyonlarında yenilikler gibi. Hatta Kolmogorov’un 1957’de ortaya attığı teorik bir temsil yaklaşımından esinlenen **PIKAN** adı verilen yeni bir model türü, geleneksel PINN’lere alternatif olarak önerilmiştir. PINN ve türevi yöntemler, biyomedikal mühendislikten akışkanlar dinamiğine, yerbiliminden kimyasal reaksiyon mühendisliğine dek geniş bir uygulama yelpazesinde başarıyla kullanılmaktadır. Örneğin, rüzgâr türbini performans tahmini, yeni malzemelerin ısı iletim hesapları veya yeraltı suyu akış modelleri gibi problemlerde PINN tabanlı çözümler araştırılmaktadır. Bu gelişmeler, YZ’nin salt bir *kara-kutu tahmin aracı* olmanın ötesine geçerek bilimin kuramsal modellerine entegre edilebileceğini göstermektedir.

Diğer yandan, büyük ölçekli hesaplamalı bilim problemlerinde YZ'nin **hızlandırıcı (accelerator)** veya **ikame model (surrogate)** olarak kullanımı da önem kazanmıştır. NASA'nın 2024 yılı projelerinden biri, çeşitli bilim disiplinlerine yönelik **temel YZ modelleri (foundation models)** geliştirmektir. *Foundation model*, devasa veri setleri üzerinde kendiliğinden gözetimli olarak eğitilmiş, çok çeşitli görevlere minimum ek eğitimle uyarlanabilen büyük ölçekli YZ modellerini ifade eder. NASA, sahip olduğu büyük bilimsel veri arşivlerini bu tür modellerle değerlendirerek, keşif sürecini hızlandırmayı ve veri-yoğun analizlerde insan yükünü azaltmayı hedeflemektedir. Örneğin **Prithvi WxC** adlı 2.3 milyar parametrelili bir hava ve iklim modeli, NASA'nın iklim verileri üzerinde ön-eğitimden geçirilmiştir. Bu modelin, *küresel hava tahminlerini yerel ölçeklere indirgeyerek iyileştirme, kasırga rotalarını önceden tahmin etme ve iklim simülasyonlarında çözünürlüğü artırma (downscaling)* gibi görevlerde başarı sağladığı belirtilmektedir. Prithvi WxC modeli, 15 gün boyunca 64 adet A100 GPU kullanılarak devasa bir veri kümesi üzerinde eğitilmiş ve sonuçta atmosferik yerçekimi dalgalarının etkilerini dahi yakalayabilen bir yetenek kazanmıştır. Böyle bir modelin, iklim ve hava tahmininin kritik olduğu farklı senaryolarda (ör. fırtınaların konum ve şiddet tahmini, bölgesel iklim değişikliği etkileri vb.) karar vericilere çok yönlü destek sağladığı rapor edilmektedir. NASA, benzer şekilde **güneş fiziği (heliophysics)** gibi alanlar için de temel modeller geliştirmeyi planlamaktadır.

YZ destekli bilimsel modellemenin bir başka boyutu da **deney tasarımı ve yeni keşifler**dir. Örneğin ilaç keşfinde **derin öğrenme** modelleri milyarlarca molekülün taranmasında veya yeni ilaç adaylarının tasarımında kullanılmaktadır. Malzeme biliminde, yeni malzemelerin özelliklerini tahmin eden YZ modelleri araştırmacılara aday malzemeleri önceliklendirmede yardımcı olmaktadır. Yine benzer şekilde, yüksek maliyetli süper bilgisayar simülasyonları (ör. astrofizik simülasyonları, büyük ölçekli CFD'ler) bazı durumlarda YZ tabanlı *metamodeller* ile yaklaşıklaştırılmakta, böylece hesaplama maliyeti düşürülmektedir. Tüm bu örnekler, YZ'nin bilimsel araştırma döngüsüne entegre edilerek hem **hesaplamaları hızlandırma** hem de **yeni içgörüler üretme** potansiyelini göstermektedir. Sonuç olarak, bilimsel modelleme alanında YZ'nin rolü giderek büyümekte; fizik yasalarını bilen sinir ağları, çok ölçekli temel modeller ve deney yönlendiren yapay zekâ sistemleri, modern bilimin araç setine eklenmektedir.

## Diğer Yapay Zekâ Kullanım Modelleri

Yukarıda ele alınanlar dışında, yapay zekânın farklı kullanım modelleri de bulunmaktadır. Bunlardan bazıları şunlardır:

- **Tanımlayıcı Analiz (Descriptive Analytics):** Geçmiş verilere odaklanarak ne olduğunu anlamaya çalışan model ve yöntemlerdir. Bu kapsamda veri madenciliği, kümeleme (cluster analizi) ve görselleştirme teknikleri kullanılarak geçmiş performansın analizi yapılır. Örneğin iş zekâsı uygulamalarında YZ, büyük veri yığınlarından anlamlı özetler çıkarıp yöneticilere sunabilir. *Klasik AI* içinde tanımlayıcı algoritmalar, geçmiş olayları inceleyerek raporlayan yapıdadır.
- **Teşhisleyici Modeller (Diagnostic Analytics):** Bir olayın *neden* gerçekleştiğini saptamaya yönelik yapay zekâ uygulamalarıdır. Hataların kök neden analizi, arıza teşhis sistemleri, sahtekârlık tespitinde anomali yakalama bu kategoriye girer. Örneğin üretimde bir makine arızasının sebebini belirleyen YZ sistemi veya siber güvenlikte ihlalin kaynağını bulan algoritmalar teşhisleyici modellere örnektir. Bu modeller nedensel çıkarımla ilişkilidir; verideki sebep-sonuç izlerini takip ederek sorunların altında yatan faktörleri açığa çıkarmaya çalışırlar.
- **Öneri Sistemleri (Recommender Systems):** Kullanıcılara kişiselleştirilmiş öneriler sunmak için YZ'nin kullanıldığı sistemlerdir. E-ticarette ürün tavsiyeleri, dijital platformlarda film/müzik önerileri, sosyal medyada içerik sıralama gibi uygulamalar bu kapsamdadır. Öneri sistemleri, kullanıcının geçmiş tercihlerini ve benzer kullanıcıların davranışlarını analiz ederek *"bu kullanıcı"*

*şunu da beğenebilir*” şeklinde tahminler üretir. Bu modeller kullanıcı deneyimini geliştirmek ve bilgi yükünü azaltmak için kritiktir. 2017-2024 arası gelişmeleri inceleyen kapsamlı bir araştırma, öneri sistemlerinin içerik bazlı ve işbirlikçi filtrelemeden derin öğrenme, grafik sinir ağları, pekiştirmeli öğrenme ve hatta büyük dil modellerine evrildiğini ortaya koymuştur. Artık bağlamsal farkındalığı olan, açıklanabilirlik ve adalet gibi ilkeleri gözeten öneri sistemleri geliştirilmektedir. Öneri sistemleri sadece e-ticaret değil, eğlence (müzik, video), sağlık (kişiye özel tedavi önerileri), finans (algoritmik ticaret tavsiyeleri) gibi pek çok alanda uygulanmaktadır.

- **Üretken Modeller (Generative AI):** Var olan verilerden öğrenerek yeni ve özgün içerik üreten yapay zekâ modellerini ifade eder. Son dönemde büyük ilgi toplayan **generative AI** uygulamaları, dil modelleriyle metin üretimi (ör. ChatGPT), görüntü üretimi (ör. DALL-E, Stable Diffusion), müzik ve tasarım üretimi gibi alanlarda çığır açmıştır. Üretken modeller, insan benzeri içerikler oluşturarak yaratıcı süreçleri destekler veya otomatikleştirir. Örneğin bir reklam metnini otomatik yazan dil modeli ya da taslak bir ürün çizimi oluşturan görüntü modeli, insan uzmanlara zaman kazandırabilir. 2024 yılında yayınlanan bir raporda, generative AI’nın bilgi-yoğun işleri temelden dönüştürdüğü; yazma, görsel tasarım, kod üretimi, sohbet etme, hatta mantık yürütme gibi bilişsel yetileri taklit ederek birçok sektörde **yapısal değişime** yol açtığı vurgulanmıştır. Bu modeller, özgün içerik oluşturma yanı sıra simülasyon, veri artırma (data augmentation) ve etkileşimli asistanlar oluşturma gibi amaçlarla da kullanılmaktadır.
- **Optimizasyon ve Planlama:** Yapay zekânın, karmaşık optimizasyon problemlerini veya eylem planlama görevlerini çözmek için kullanımı da ayrı bir kategori oluşturur. **Pekiştirmeli öğrenme (Reinforcement Learning)** algoritmaları bu alanda öne çıkar; örneğin bir robotun yol planlaması, oyun oynayan bir ajan, fabrika üretim çizelgelemesi gibi problemlerde RL ajanları insan uzmanlığını aşan stratejiler bulabilir. Benzer şekilde YZ, klasik operasyon araştırması problemleri olan rota optimizasyonu, çizelgeleme, kaynak atama gibi konularda da hibrit yöntemlerle kullanılmaktadır. Bu kullanım modeli, *karar otomasyonu* olarak da görülebilir; yani insanın karar verme süreci tamamen otonom bir yapay ajan tarafından devralınır (ör. otonom araçların trafikte kendi kararlarını vermesi). 2023 ve sonrasında, optimizasyon problemlerinde YZ ve yöneylem araştırması tekniklerinin bütünleştirilmesi sıkça tartışılmaktadır. Hedef, YZ’nin öğrenme becerileri ile klasik optimizasyonun kesinlik garantilerini bir araya getirerek güvenilir ve etkili planlama sistemleri geliştirmektir.
- **Sınıflandırma ve Tanıma Sistemleri:** Bu kategori, YZ’nin en temel kullanım alanlarından biridir. Görüntü tanıma, ses tanıma, metin sınıflandırma, nesne tespiti, yüz tanıma gibi görevler, derin öğrenme modellerinin (özellikle **CNN** ve **Transformers** tabanlı ağların) yoğun kullanıldığı alanlardır. Örneğin, tıbbi görüntülerde tümör tespiti yapan bir model veya e-postalarda spam ayrımı yapan bir filtre, sınıflandırma modellerine örnektir. Bu modeller genelde denetimli öğrenme ile eğitilir ve belirli bir girdiyi uygun kategori/etiket ile eşleştirmeyi amaçlar. Son yıllarda model mimarileri gelişirken (ResNet, EfficientNet, Vision Transformer vb.), aynı zamanda daha **geniş ölçekli verisetleri** ve **ön eğitim (pre-training)** yaklaşımları ile bu tanıma sistemlerinin doğruluğu ve genelleme kabiliyeti çok artmıştır. Bu sayede sürücüsüz araçlardan akıllı şehir uygulamalarına, tarımdan güvenliğe kadar geniş bir yelpazede sınıflandırma/tanıma modelleri kullanılmaktadır.
- **Anomali Tespiti (Anomaly Detection):** YZ’nin bir diğer kullanım modeli, normalden sapmaları veya beklenmedik desenleri otomatik tespit etmektir. Bu, özellikle siber güvenlik (olağandışı ağ trafiğini yakalama), finans (şüpheli işlem/fraud tespiti), endüstriyel IoT (cihaz arızası belirtisi olan anormal sensör verilerini saptama) gibi alanlarda önemlidir. Anomali tespit modelleri genelde çoğunlukla gördüğü “normal” veriden bir profil öğrenir ve yeni gözlemlerin bu profilden ne kadar saptığına bakarak alarm üretir. 2023’e kadar uzanan derin öğrenme tabanlı anomali tespit

araştırmaları, özellikle **zaman serilerinde** LSTM, VAE (Variational Autoencoder), GAN ve Transformer gibi mimarilerin başarıyla uygulandığını göstermiştir. Örneğin endüstriyel bir makineden gelen çok boyutlu sensör verisinde, eğitim esnasında normal çalışmayı temsil eden bir derin model (bir autoencoder ağı gibi) kurulup, gerçek zamanlı veride bu modelin hatası artmaya başladığında anomali alarmı tetiklenebilir. Böylece olası bir arıza erken tespit edilip müdahale edilebilir. Anomali tespiti, aynı zamanda sağlık alanında hastalık belirtilerini erken yakalamak veya kalite kontrol süreçlerinde hatalı ürünleri ayırt etmek için de kullanılmaktadır.

Yukarıda sayılanlar, yapay zekânın temel kullanım modellerinin bir özetidir. **Tanımlayıcı, teşhis edici, öngörücü ve reçeteleyici** (prescriptive) olarak da adlandırılan bu dört ana analitik kategorisi, literatürde sıkça vurgulanır ve birbirini tamamlar niteliktedir. Tanımlayıcı ve teşhisleyici modeller geçmiş analiz edip nedenleri ortaya çıkarırken, öngörücü modeller geleceği tahmin eder; reçeteleyici modeller ise *“ne yapmalıyız”* sorusuna yanıt arar ve genellikle karar destek sistemleri şeklinde karşımıza çıkar. Üretken yapay zekâ ise son dönemde bu klasik ayrımın ötesine geçerek, yapay zekânın yaratıcı ve bilişsel roller üstlenebileceği yepyeni kullanım alanları ortaya koymuştur.

## Son Gelişmeler ve Trendler

2024 sonrası yapay zekâ alanındaki çalışmalar, yukarıda bahsedilen tüm kullanım modellerinde **daha derin mimariler, daha büyük ölçekli veriler ve artan bir disiplinlerarası entegrasyon** eğilimi sergiliyor. Causality (nedensellik) ile derin öğrenmenin bütünleşmesi, karar destek sistemlerinde insan-odaklı ve açıklanabilir tasarımların yükselişi, tahminlemede temel modellerin ve mimari çeşitliliğin artışı, bilimsel modellemede fiziğin ve verinin harmanlanması gibi gelişmeler, yapay zekâ araştırmalarının sınırlarını genişletiyor. Özellikle büyük dil ve görsel modellerin sağladığı atılımlar, hemen her alana nüfuz ederek yeni uygulama örnekleri yaratıyor (örneğin, bir LLM’nin hem nedensel sorgulara yanıt verip hem de bir karar destek ara yüzünde kullanıcıyla etkileşime girmesi). Bununla birlikte, **güvenilirlik, şeffaflık, etik ve düzenleyici uygunluk** gibi konular da her zamankinden daha fazla önem kazanmış durumda.

Akademik literatürde 2024 ve 2025 yıllarında yayımlanan makaleler, yapay zekânın kullanım modelleri konusunda daha bütüncül yaklaşımları işaret etmektedir. Örneğin, zaman serisi tahminleme alanında yayınlanan kapsamlı bir derleme, **melez ve çok disiplinli yaklaşımların (ör. nedenselliği de dikkate alan tahmin modelleri)** önemine vurgu yapmıştır. Keza karar destek alanında AAAI 2025’de sunulan çalışmalar, **YZ ile operasyonel araştırma tekniklerinin** birleştiği, *“güvenilir ve şeffaf karar yapıcı sistemler”* oluşturulmasına dair yöntemler önermektedir. Bilhassa karar verme süreçlerinde YZ’nin getirdiği davranışsal ve toplumsal sorular (insanların YZ tavsiyelerini nasıl algıladığı, bu sistemlerin ekonomiye ve işgücüne etkileri gibi) yeni araştırma konuları olarak ortaya çıkmaktadır. Nedensel çıkarımda ise büyük ölçekli **CausalNLP, CausalRL** (nedensel pekiştirmeli öğrenme) gibi alt alanların filizlendiği; LLM’lerin ve grafik ağlarının nedensel keşifte kullanılmasının sıcak bir araştırma konusu olduğu görülmektedir.

Sonuç itibarıyla, yapay zekâ modellerinin kullanım amaçları birkaç ana başlık altında toplanabilse de, bunların kesişimleri ve birlikte kullanım örüntüleri giderek karmaşıklaşıyor. Güncel çalışmalar, yapay zekâyı insan kararını destekleyen bir araçtan ziyade, *insanla birlikte düşünen, bilimsel keşfi hızlandıran, yaratıcı süreçlere ortak olan* bir partner haline getirmeyi hedefliyor. Bu doğrultuda geliştirilen teknik mimariler ve uygulama örnekleri, yapay zekânın önümüzdeki yıllarda daha da bütünsel ve etkili biçimde hayatımızın her alanına nüfuz edeceğini gösteriyor. Gözlenen bu hızlı ilerlemelerin sağlıklı bir şekilde topluma kazandırılması ise ancak disiplinlerarası iş birliği, etik çerçeveler ve sürekli araştırma ile mümkün olacaktır.

**Kaynaklar:** Güncel akademik makaleler, konferans bildirileri ve arXiv ön baskıları belirtilen formatta kaynak gösterilerek metin içerisinde sunulmuştur. Bu kaynaklar arasında 2024 ve 2025 yıllarında yayınlanmış olanlar özellikle vurgulanmış, ele alınan konuların teknik detayları ve uygulama sonuçları bu kaynaklardan özetlenmiştir. Bu sayede, yapay zekâ kullanım modellerinin son durumu ve geleceğe dönük yönelimleri, sağlam bir literatür zemini üzerinde aktarılmaya çalışılmıştır.

---